Стратегии деплоя и релиз-процессы

Арзамасова Анна
Эксперт курса «Интеграция ИИ»



Проверка связи

Если у вас нет звука:

- убедитесь, что на вашем устройстве и на колонках включён звук
- обновите страницу вебинара (или закройте страницу и заново присоединитесь к вебинару)
- откройте вебинар в другом браузере
- перезагрузите компьютер (ноутбук) и заново попытайтесь зайти

Поставьте в чат:

\+ если меня видно и слышно

— если нет

Рекомендации

→ Если смотрите с компьютера

- Используйте браузеры Google Chrome или Microsoft Edge
- Если есть проблемы с изображением или звуком, обновите страницу — **F5**

→ Если смотрите с мобильного телефона или планшета

- Перейдите с мобильного интернет-соединения на **Wi-Fi**
- Если есть проблемы с изображением или звуком, перезапустите приложение на телефоне
- Предварительно проверьте, подходит ли ваше устройство для подключения к вебинару, по ссылке

Анна Арзамасова

О спикере:

- инженер в сфере авиации, сотрудник НИИ
- специалист по интеллектуальным системам управления транспортом
- преподаватель Московского Политеха
- Преподаватель и разработчик образовательных программ на стыке инженерии, программирования и искусственного интеллекта



Разбор домашнего задания вебинара 9

ОРГМОМЕНТ

От сервиса — к безопасному релизу

Вебинар 9: построили работающий сервис. Вебинар 10: как новая версия попадает к пользователям, не ломая работу текущих.



Цели занятия

После занятия вы сможете:

- **сравнивать** blue-green и canary-деплой, A/B-тестирование, feature flags и shadow-запуск;
- **выбирать и обосновывать** стратегию деплоя для своего ML-сервиса;
- **определять** метрики и пороги, при которых релиз продолжается, останавливается или откатывается;
- **составлять** план отката: кто решает, как быстро, что происходит с уже обработанными запросами.

План вебинара

1. Зачем нужна стратегия деплоя
2. Blue-green и canary
3. A/B-тестирование и feature flags
4. Shadow-запуск и откат
5. Практика: стратегия деплоя
6. Итоги

Зачем нужна стратегия деплоя

ЧАСТЬ 1

Деплой с простоем (recreate)

Остановить старую версию, поставить новую, запустить. Во время замены сервис недоступен, откат — повторный простой.



Определение

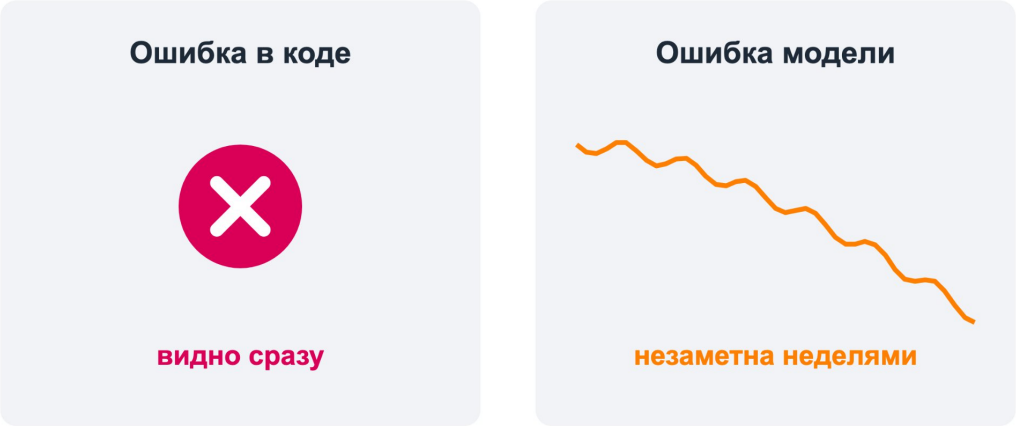
Стратегия деплоя — заранее продуманный способ заменить рабочую версию сервиса на новую: без простоя, с ограничением ущерба от ошибки и быстрым откатом.



Ошибку в коде видно сразу — сервис падает. Ошибку модели можно не видеть неделями — она просто отвечает хуже, без единого исключения

Пример

Модель антифрода обновили и сразу деплоили на 100% трафика. Через неделю: ложных срабатываний стало больше — тестовая выборка не отражала текущее поведение пользователей.

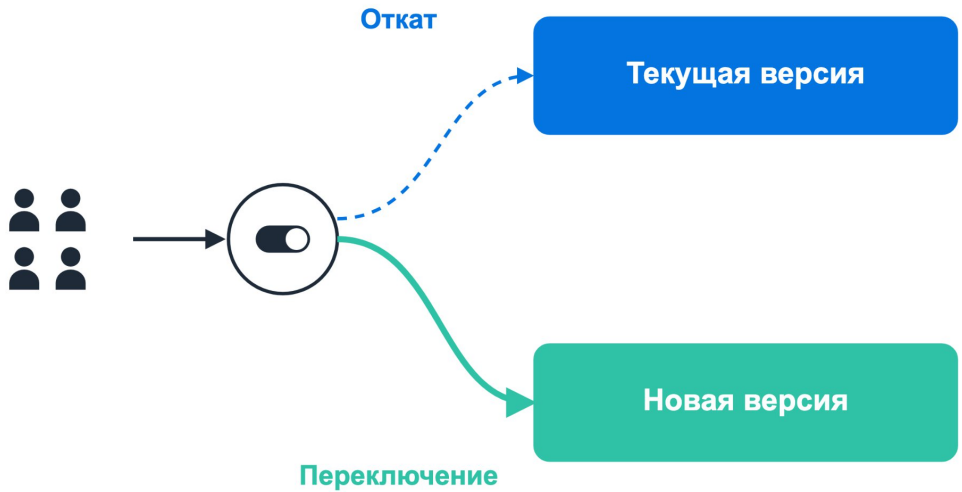


Blue-green и canary

ЧАСТЬ 2

Blue-green деплой

Два идентичных окружения: «синее» (текущая версия) и «зелёное» (новая, проверяется отдельно). Переключение трафика — мгновенное.



Blue-green: плюсы и минусы

Плюс

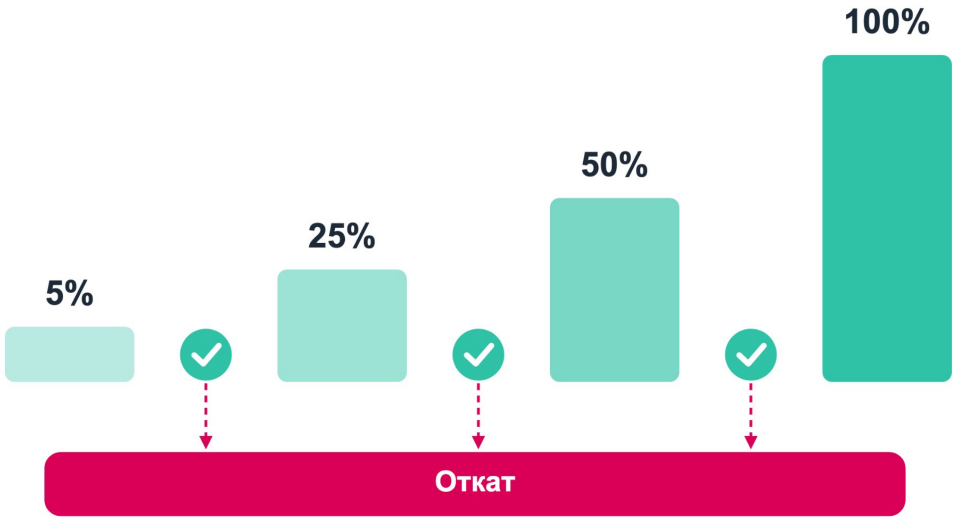
- Мгновенный откат — секунды
- Синее окружение никуда не делось

Минус

- Два полных окружения одновременно
- Удвоенные затраты на время деплоя

Canary-деплой

Новая версия сначала получает малую долю трафика (5%), и постепенно доля растёт — 5% → 25% → 50% → 100% — если метрики в норме.



Canary: плюсы и минусы

Плюс

- Проблема затрагивает малую часть пользователей
- Можно остановить на любом этапе

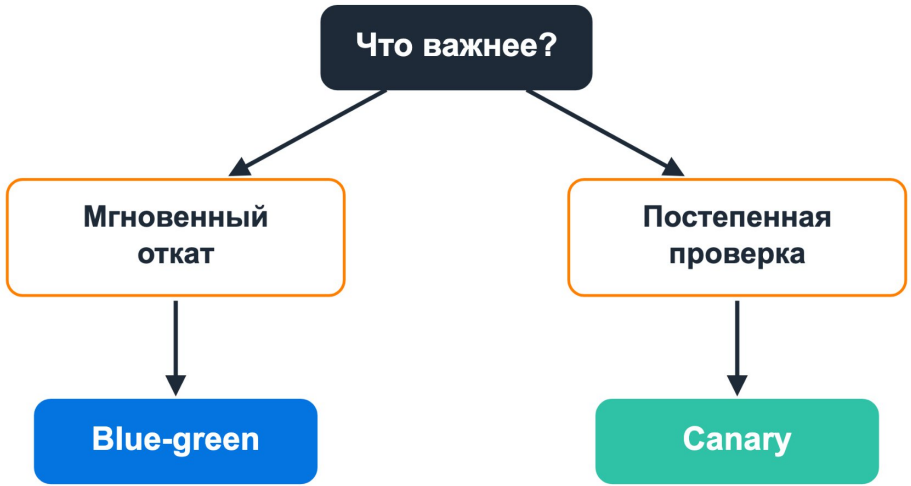
Минус

- Нужна инфраструктура точного роутинга трафика
- Полное раскатывание — часы или дни

Контрольный вопрос: переключение мгновенно для всех, или постепенно для растущей доли? Мгновенно — blue-green, постепенно — canary

Как выбирать

Blue-green — когда откат должен быть мгновенным. Canary — когда важно постепенно набирать уверенность в новой версии на реальном трафике.

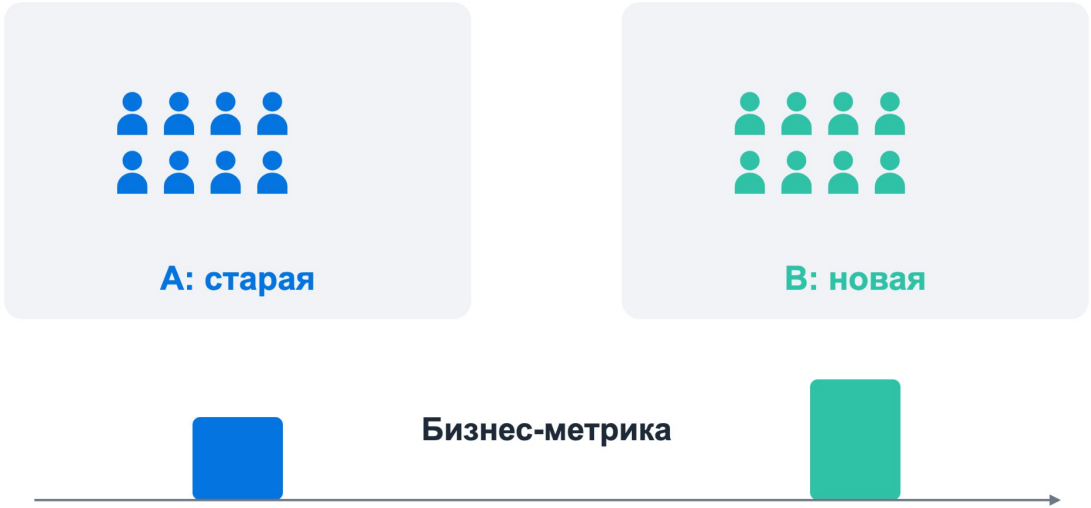


A/B-тестирование и feature flags

ЧАСТЬ 3

A/B-тестирование

Отвечает не на вопрос технической стабильности, а на вопрос бизнес-эффективности: группа A видит старую версию, группа B — новую, сравниваются бизнес-метрики.



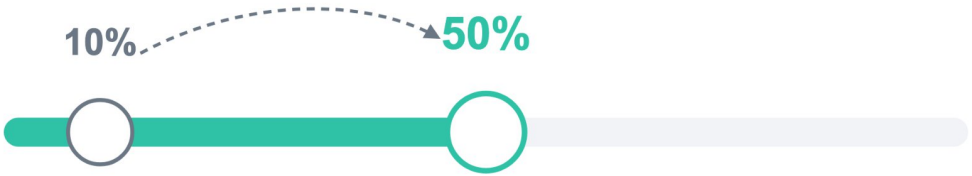
Отличие от canary

A/B-тест может длиться недели — цель не убедиться, что ничего не сломалось, а накопить статистически значимую разницу в бизнес-метрике.



Feature flags

Механизм включения/выключения функций без нового деплоя, через конфигурацию «на лету». Для ИИ-систем — управление долей пользователей на новой модели.



Доля на новой модели — без нового деплоя

Пример

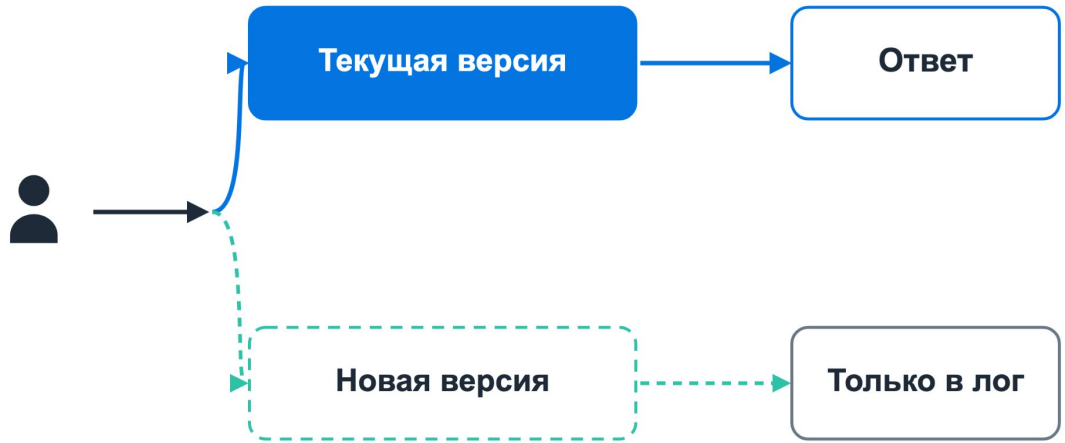
Сервис деплоит код с поддержкой двух моделей один раз, а дальше плавно переключает трафик через feature flag — без повторных деплоев.

Shadow-запуск и откат

ЧАСТЬ 4

Shadow-запуск

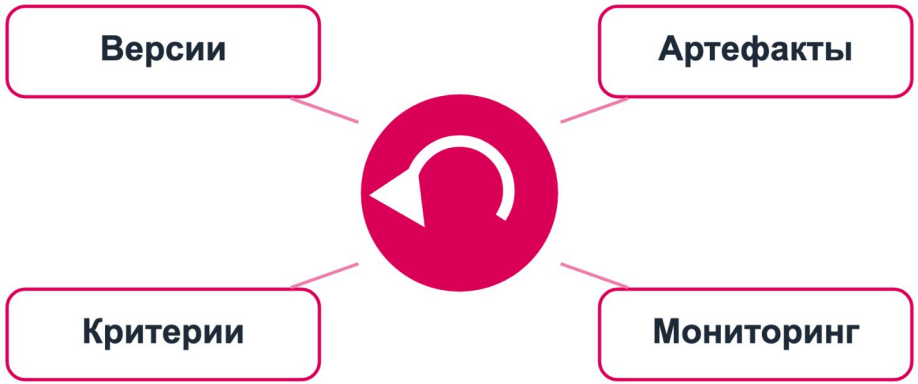
Новая версия получает копию реального трафика и обрабатывает его параллельно со старой, но результат не влияет на ответ пользователю — только логируется.



Shadow-запуск — нулевой риск: что бы ни предсказала новая модель, пользователь этого не увидит

Rollback (откат)

Процедура возврата к предыдущей рабочей версии после того, как новая версия показала проблему в проде.



Условия быстрого отката (готовятся заранее)

Версионирование модели и кода

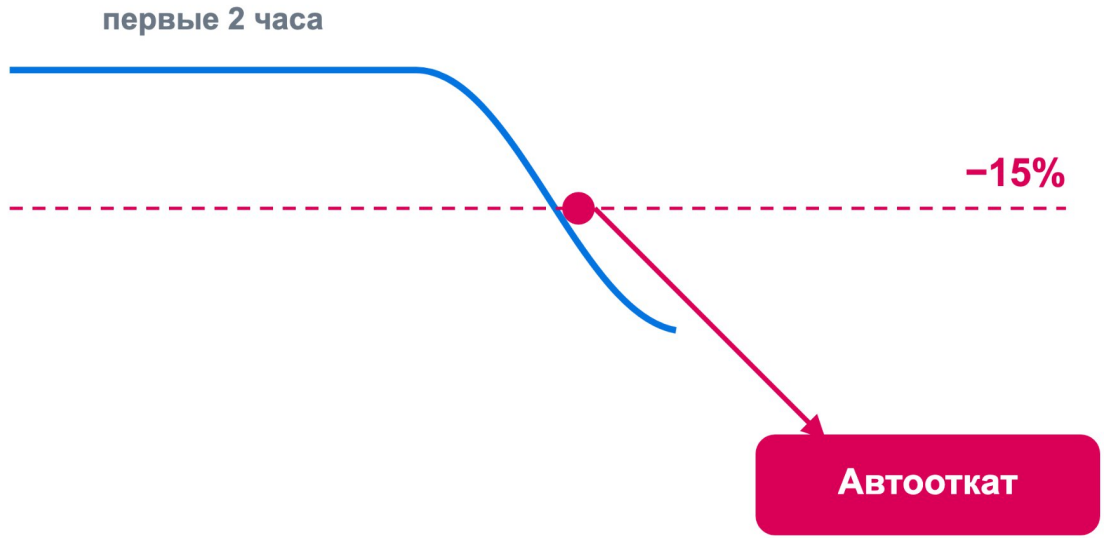
Сохранённые артефакты предыдущей версии

Наблюдаемость — быстрое обнаружение проблемы

Чёткие критерии запуска отката

Пример rollback-плана

Если доля дослушиваний рекомендованного трека падает более чем на 15% за первые 2 часа — автоматический откат на предыдущую версию модели.



Стратегия деплоя для своего кейса

ПРАКТИКА

Шаг 1

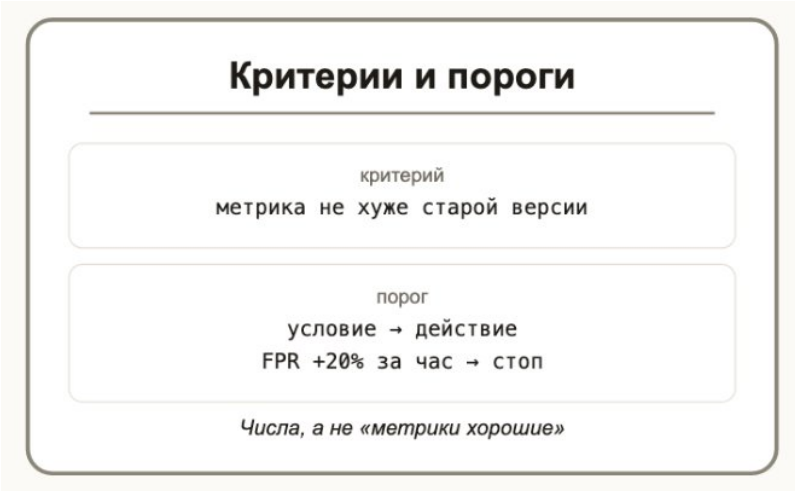
Выберите стратегию деплоя (blue-green, canary, их сочетание) и обоснуйте выбор для своего кейса.





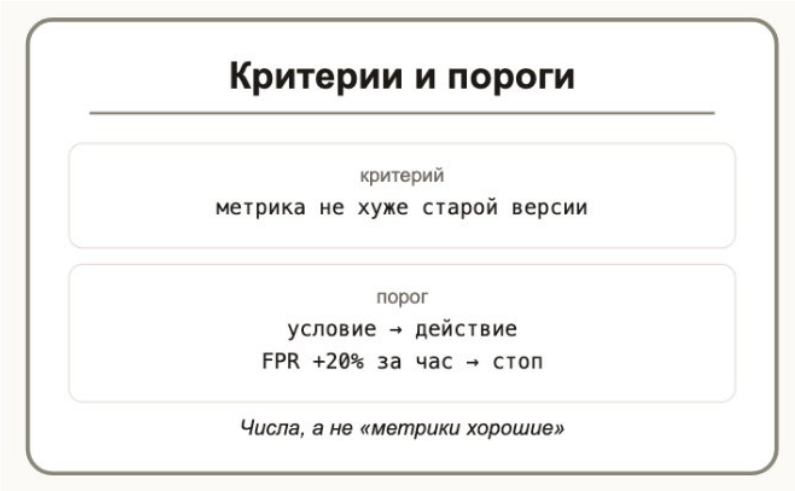
Шаг 2

Опишите критерии успешности релиза: по каким метрикам поймёте, что новая версия не хуже старой.



Шаг 3

Зафиксируйте пороги: при каких значениях метрик деплой останавливается или откатывается.



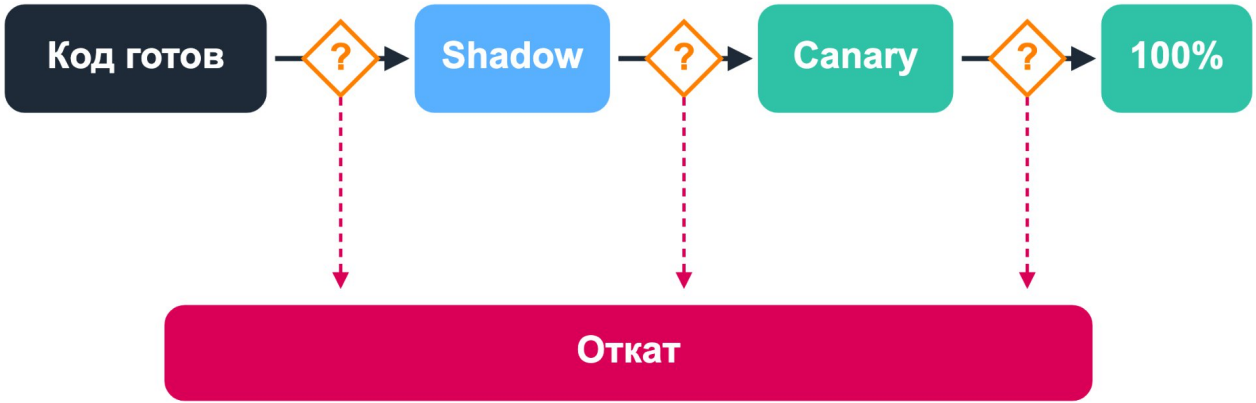
Шаг 4

Сформулируйте план отката: кто принимает решение, как быстро, что с уже обработанными запросами.



Шаг 5

Нарисуйте схему процесса деплоя на Holst: от «код готов» до «100% трафика», с точками решений.



Если не работает

Сложно выбрать стратегию
критична ли скорость мгновенного отката больше, чем постепенное снижение риска?

Непонятна метрика успешности
возьмите ту же, что определяли в практике вебинара 7

Holst недоступен
опишите схему текстовым списком этапов со стрелками-переходами

Вы узнали

Как безопасно проверять новую версию сервиса или модели и снижать риск для пользователей при релизе. На практике: перед релизом ответьте на три вопроса — на какой доле трафика проверяем, по какой метрике решаем и как откатываемся.

Главная мысль:

Ошибка модели может неделями оставаться незаметной, поэтому новую версию выпускают постепенно и под контролем метрик, а пороги и план отката готовят до релиза, а не во время инцидента.

Что мы разобрали сегодня

ИТОГИ

Blue-green — мгновенный откат ценой двух окружений.
Canary — постепенное снижение риска ценой более медленного процесса.

A/B-тестирование проверяет бизнес-эффективность, не только техническую стабильность

Shadow-запуск проверяет модель с нулевым риском.
Готовность к откату — обязательная часть стратегии, продуманная заранее.

Стратегия	На какой вопрос отвечает	Кто видит новую версию	Главный плюс	Главная цена
Blue-green	Готова ли новая версия к полному переключению	Все сразу — после мгновенного переключения	Откат за секунды	Два полных окружения одновременно
Canary	Стабильна ли версия технически	Растущая доля: 5% → 25% → 50% → 100%	Ошибка задевает малую часть пользователей	Точный роутинг; часы или дни
A/B-тест	Какая версия лучше по бизнес-метрике	Группа B; группа A — старую	Решение на основе бизнес-эффекта	Может длиться недели — нужна значимая разница
Shadow	Как новая модель ведёт себя на реальном трафике	Никто — результат только в логах	Нулевой риск для пользователя	Влияния на ответы нет — только сравнение по логам
Feature flags	Механизм управления долей без нового деплоя	Та доля, которую задаёт флаг	Переключение «на лету»	Код должен поддерживать обе модели

Домашнее задание

Опишите стратегию деплоя для своего проекта: схема + описание стратегии, критериев успешности, порогов и плана отката. 2 страницы.

Мост к вебинару 11

На следующем вебинаре — как «упаковать» сервис в контейнер с Docker, чтобы он одинаково работал на любой машине, и собрать несколько сервисов через Docker Compose.

СПАСИБО

До встречи на вебинаре 11

Стратегии деплоя и релиз-процессы

Арзамасова Анна
Эксперт курса «Интеграция ИИ»

